Segmentacja obszaru odczytu wodomierza

Kamień milowy 1

Definicja problemu, dobór danych i projekt eksperymentu

Wojciech Szewczyk

1 Cel i zakres projektu

Celem projektu jest automatyczne wskazanie obszaru z cyframi na zdjęciu wodomierza. Zadanie ma postać segmentacji binarnej: każdy piksel obrazu jest przypisywany do obszaru odczytu albo do tła. Wynikiem działania modelu jest maska pokazująca położenie tego obszaru.

Takie rozwiązanie może przygotowywać zdjęcia do automatycznego odczytu zużycia wody. Projekt obejmuje lokalizację obszaru odczytu, bez rozpoznawania cyfr. Główne pytanie badawcze brzmi: **czy augmentacja danych poprawia jakość segmentacji w porównaniu z uczeniem tej samej sieci bez augmentacji?**

2 Zbiór danych i jego przygotowanie

W projekcie wykorzystano zbiór *Water Meters Dataset*, udostępniony w serwisie Kaggle przez użytkownika tapakah68.[1] Zestaw zawiera 1244 kolorowe zdjęcia JPG i 1244 odpowiadające im maski. Szerokości obrazów źródłowych wynoszą 864–2058 px, a wysokości 480–2168 px.

Zbiór odpowiada bezpośrednio wybranemu zadaniu i zawiera gotowe oznaczenia, dzięki czemu umożliwia zarówno uczenie nadzorowane, jak i ilościową ocenę predykcji. Zdjęcia różnią się rozmiarem, oświetleniem i ustawieniem wodomierza. Istotnym utrudnieniem jest mały udział obszaru odczytu: po preprocessingu 97,69% pikseli masek stanowi tło. Sama dokładność pikselowa może więc dawać myląco dobry wynik nawet przy słabej segmentacji.

Przygotowanie danych obejmuje skalowanie obrazów do 512×512 pikseli, przeliczenie wartości do zakresu $[0, 1]$, rozciąganie kontrastu na podstawie 2. i 98. percentyla oraz filtr medianowy 3×3. Maski są binaryzowane przy progu 127 i skalowane metodą najbliższego sąsiada.

W projekcie rozróżniono **podstawowy preprocessing**, wspólny dla wszystkich podzbiorów, oraz **losową augmentację**, która urozmaica przykłady podczas treningu. Augmentacja nie jest warunkiem gotowości zbioru: jest elementem porównywanych wariantów uczenia. Zbiory walidacyjny i testowy podlegają wyłącznie podstawowemu preprocessingowi.

Finalny podział utworzono z ziarnem 42. Zbiór treningowy służy do uczenia wag, walidacyjny do wyboru checkpointu i wariantu, a testowy do końcowej oceny. Udziały klas obliczono z masek po skalowaniu do 512×512:

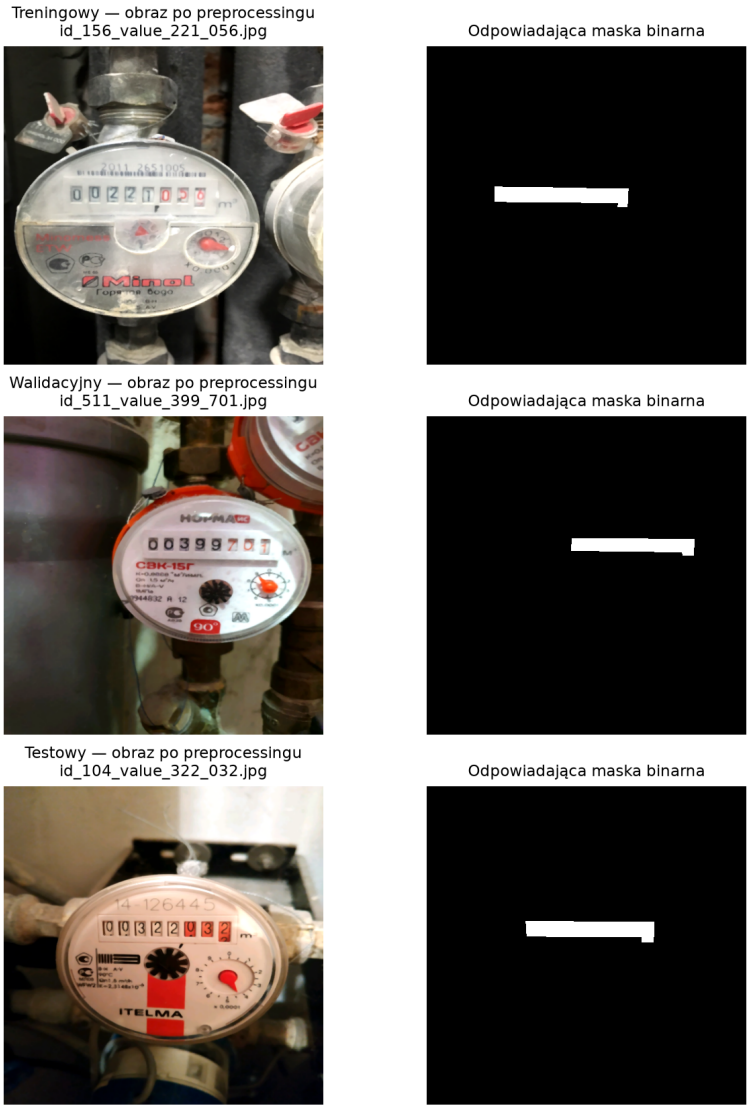
Zbiór	Pary	Udział zbioru	Obszar odczytu	Tło
Train	995	79,98%	2,31%	97,69%
Val	124	9,97%	2,30%	97,70%
Test	125	10,05%	2,37%	97,63%
Łącznie	1244	100,00%	2,31%	97,69%

Pary zapisano w katalogach train/val/test. Podzbiory są rozłączne po nazwach plików; kontrola sum SHA-256 nie wykazała również identycznych plików zdjęć pod różnymi nazwami. Preprocessing jest wykonywany przy wczytywaniu danych.

[1] Źródło danych: `https://www.kaggle.com/datasets/tapakah68/yandextoloka-water-meters-dataset`.

2.1 Weryfikacja i przykłady po preprocessingu

Cały zbiór został przetworzony i jest gotowy do treningu. Kontrola objęła 1244 z 1244 par: bez błędów odczytu, brakujących par, niezgodnych wymiarów obrazu i maski ani pustych masek. Wszystkie obrazy po preprocessingu mają kształt $3\times512\times512$ i wartości w $[0, 1]$, a maski $1\times512\times512$ i wartości 0 lub 1. Oba tensory mają typ `float32`.



Przykładowe pary z każdego podzbioru: po lewej obraz po preprocessingu, po prawej odpowiadająca mu maska referencyjna. Biały obszar oznacza miejsce odczytu. Przykłady nie zawierają losowej augmentacji.

3 Założenia rozwiązania

Podstawą rozwiązania jest sieć konwolucyjna U-Net w bibliotece PyTorch, z czterema poziomami kodera, podwójnymi blokami konwolucyjnymi i 16 filtrami w pierwszym bloku. Połączenia między koderem i dekoderem pomagają zachować informację o położeniu obszaru odczytu.

Docelowe narzędzie powinno przyjmować zdjęcie, wyznaczać maskę oraz umożliwiać zapis wyniku i podgląd maski nałożonej na obraz.

4 Hipotezy i plan eksperymentów

Porównanie obejmie trzy warianty tej samej architektury. Pozwoli to ocenić wpływ augmentacji bez jednoczesnej zmiany budowy sieci.

Wariant	Przygotowanie danych treningowych
A — baseline	Podstawowe przetwarzanie, bez losowej augmentacji; punkt odniesienia.
B	Jak w A, dodatkowo odbicia poziome i pionowe oraz obroty do $\pm 10^{\circ}$.
C	Jak w B, dodatkowo losowa zmiana jasności o maksymalnie 20%.

Hipoteza H1: wariant B uzyska wyższy średni Dice na zbiorze walidacyjnym niż wariant A.

Hipoteza H2: wariant C uzyska wyższy średni Dice na zbiorze walidacyjnym niż wariant B.

Przekształcenia geometryczne będą identyczne dla zdjęcia i maski; zmiana jasności dotyczy tylko zdjęcia. Augmentacja obejmie wyłącznie trening.

Warunki porównania będą wspólne: ten sam podział danych, rozdzielczość, architektura i ustalone ziarna losowe. Przyjęto funkcję straty `BCEWithLogitsLoss`, optymalizator Adam z learning rate 10^{-4} i `weight decay` 10^{-4} oraz batch size równy 4. Limit treningu wyniesie 100 epok, z redukcją learning rate przy zastoju i zatrzymaniem po 5 epokach bez poprawy straty walidacyjnej.

Dla każdego wariantu zostanie zapisany checkpoint o najniższej stracie walidacyjnej. Następnie warianty zostaną porównane według średniego Dice na walidacji. W planowanym porównaniu wyniki testowe nie będą służyć do strojenia parametrów ani wyboru wariantu. Końcowy test zostanie wykonany po wczytaniu wag wybranego checkpointu. Zestawienie wyników będzie zawierać konfigurację, liczbę epok i metryki. Pojedyncze przebiegi dadzą ocenę wstępną; małych różnic nie należy traktować jako rozstrzygających bez powtórzeń.

5 Metryki i kryteria oceny

- **Dice** — główna metryka, określająca zgodność przewidzianego obszaru z maską referencyjną. Posłuży do porównania wariantów.
- **IoU** — udział części wspólnej predykcji i maski w ich sumie; uzupełni ocenę pokrycia obszaru odczytu.
- **Odległość Hausdorffa** — dodatkowa miara rozbieżności przestrzennej masek, wyrażona w pikselach przy rozdzielczości 512×512.
- **Dokładność pikselowa** — miara pomocnicza, interpretowana z uwzględnieniem dużego udziału tła.

Metryki będą liczone dla poszczególnych zdjęć i uśredniane dla zbioru. Roboczym celem jakościowym jest średni Dice co najmniej 0,85 na teście. Jest to przyjęte kryterium projektu, a nie uniwersalny próg użyteczności. Ocenę uzupełni przegląd najlepszych i najgorszych predykcji oraz opis błędów, np. pominięcia obszaru odczytu lub zaznaczenia fragmentu tła.

W końcowym etapie planowana jest warstwa XAI oparta na zasłanianiu kolejnych fragmentów zdjęcia i pomiarze zmiany odpowiedzi modelu w ustalonym obszarze odczytu. Powstała mapa wpływu pomoże sprawdzić, czy predykcja zależy głównie od tego obszaru, czy również od otoczenia. Będzie to uzupełnienie metryk i analizy błędów.